第5回　代表的な確率分布

分布を表す式、パラメータの意味、期待値と分散を組にして覚えよう。回数を数える離散分布と、待ち時間を表す連続分布の関係が見えてくる。

確率質量と確率密度

X の分布を $\mu_X(B) = P(X \in B)$ とする。離散型なら

$$P(X = x) = p_X(x), \qquad p_X(x) \geq 0, \qquad \sum_x p_X(x) = 1.$$

ある非負可測関数 f_X により $\mu_X(B) = \int_B f_X(x)\,dx$ と書けるとき、f_X を確率密度という。$\int_{\mathbb{R}} f_X = 1$ であり、可積分な $g(X)$ に対し

$$\mathbb{E}[g(X)] = \sum_x g(x)p_X(x) \quad \text{または} \quad \mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x)f_X(x)\,dx.$$

密度の高さは一点の確率ではない。密度があれば $P(X = x) = 0$ である。また、分布関数が連続でも密度をもつとは限らない。

ベルヌーイ分布と二項分布

$0 < p < 1$ とし、$P(B = 1) = p$、$P(B = 0) = 1 - p$ なら $B \sim \mathrm{Bern}(p)$ と書く。独立な $B_1, \dots, B_n \sim \mathrm{Bern}(p)$ の和 S_n は二項分布に従う。

$$P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (0 \leq k \leq n), \qquad \mathbb{E}[S_n] = np, \quad \mathrm{Var}(S_n) = np(1-p).$$

k 個の成功の配置が $\binom{n}{k}$ 通りある。期待値は線形性から、分散は独立性と $B_j^2 = B_j$ から計算できる。

ポアソン分布とまれな事象の極限

$\lambda > 0$ に対し、$X \sim \mathrm{Poi}(\lambda)$ とは

$$P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!} \quad (k = 0, 1, \dots), \qquad \mathbb{E}[X] = \lambda, \quad \mathrm{Var}(X) = \lambda$$

である。$\sum_{k \geq 0} \lambda^k / k! = e^{\lambda}$ より確率の総和は 1。また $\mathbb{E}[X(X-1)] = \lambda^2$ を使うと分散を求めやすい。固定した k に対し

$$\binom{n}{k}(\lambda/n)^k(1-\lambda/n)^{n-k} \longrightarrow e^{-\lambda}\frac{\lambda^k}{k!}.$$

多数の独立な機会に小さな確率で起こる事象の総回数を、この極限が記述する。

幾何分布：最初の成功までの試行回数

$X \sim \mathrm{Geo}(p)$ は、本資料では $1, 2, \dots$ の値をとる規約とする。

$$P(X = k) = (1-p)^{k-1}p, \qquad \mathbb{E}[X] = \frac{1}{p}, \qquad \mathrm{Var}(X) = \frac{1-p}{p^2}.$$

$P(X > m) = (1-p)^m$ より、整数 $m, n \geq 0$ に対し

$$P(X > m + n \mid X > m) = \frac{(1-p)^{m+n}}{(1-p)^m} = P(X > n).$$

一様分布：区間の長さに比例する確率

$a < b$ に対し、$X \sim \mathrm{U}(a,b)$ の密度とモーメントは

$$f_X(x) = \frac{1_{[a,b]}(x)}{b-a}, \qquad \mathbb{E}[X] = \frac{a+b}{2}, \qquad \mathrm{Var}(X) = \frac{(b-a)^2}{12}.$$

$a \le s < t \le b$ なら $P(s < X \le t) = (t-s)/(b-a)$。$U \sim \mathrm{U}(0,1)$ なら $a + (b-a)U \sim \mathrm{U}(a,b)$ である。

指数分布：連続時間の待ち時間

$\lambda > 0$ を rate とする $X \sim \mathrm{Exp}(\lambda)$ の密度は

$$f_X(x) = \lambda e^{-\lambda x} 1_{[0,\infty)}(x), \qquad P(X > t) = e^{-\lambda t} \quad (t \ge 0).$$

部分積分、または尾確率の積分によって

$$\mathbb{E}[X] = \frac{1}{\lambda}, \qquad \mathbb{E}[X^2] = \frac{2}{\lambda^2}, \qquad \mathrm{Var}(X) = \frac{1}{\lambda^2}.$$

$s, t \ge 0$ に対して $P(X > s+t \mid X > t) = e^{-\lambda s}$。幾何分布と同じく記憶なし性質をもつが、変数は連続時間を表す。

ガンマ分布：形状と rate を区別する

$\alpha, \beta > 0$ に対し $\mathrm{Gamma}(\alpha, \beta)$ を rate 表示で定義する。

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x}\, dx, \qquad f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \quad (x > 0).$$

$x \le 0$ では密度を 0 とする。$\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$ を用いると

$$\mathbb{E}[X^r] = \frac{\Gamma(\alpha+r)}{\beta^r \Gamma(\alpha)} \quad (r > -\alpha), \qquad \mathbb{E}[X] = \frac{\alpha}{\beta}, \quad \mathrm{Var}(X) = \frac{\alpha}{\beta^2}.$$

$\alpha = 1$ は指数分布である。独立な $\mathrm{Exp}(\beta)$ 変数 m 個の和は $\mathrm{Gamma}(m, \beta)$ に従い、m 回目の到着までの待ち時間を表す。 scale $\theta = 1/\beta$ を使う本では平均は $\alpha\theta$、分散は $\alpha\theta^2$ となる。

正規分布：中心と幅を二つのパラメータで表す

$m \in \mathbb{R}$、$\sigma > 0$ に対し、$X \sim N(m, \sigma^2)$ の密度は

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2/(2\sigma^2)}, \qquad \mathbb{E}[X] = m, \quad \mathrm{Var}(X) = \sigma^2.$$

$Z \sim N(0,1)$ なら $m + \sigma Z \sim N(m, \sigma^2)$ である。対称性から $\mathbb{E}[Z] = 0$、部分積分から $\mathbb{E}[Z^2] = 1$。正規化に使う Gauss 積分と、二項分布との関係は次回に扱う。

演習問題

1. $X \sim \mathrm{Exp}(\lambda)$ の平均、二次モーメント、分散を積分で求め、記憶なし性質を示せ。
2. 分布関数 F_X が連続なら $P(X = x) = 0$（すべての x）を示せ。さらに、この性質だけから確率密度の存在を結論してよいか考えよ。
3. $X \sim \mathrm{Gamma}(\alpha, \beta)$ の密度の積分が 1 であることと、平均・分散の公式を、変数変換 $u = \beta x$ によって確かめよ。
4. 正の確率変数 T の生存関数 $G(t) = P(T > t)$ が連続で正、 $G(s+t) = G(s)G(t)$（$s, t \geq 0$）、$G(0) = 1$、$G(t) \to 0$ を満たすとする。 $G(t) = e^{-ct}$（ある $c > 0$）を示せ。

レポート問題

1. $X \sim \mathrm{Poi}(\lambda)$ の平均と分散を求めよ。独立な $X \sim \mathrm{Poi}(\lambda)$、$Y \sim \mathrm{Poi}(\mu)$ に対し、畳み込み和から $X + Y \sim \mathrm{Poi}(\lambda + \mu)$ を示せ。
2. $X \sim \mathrm{Geo}(p)$ の平均と分散、記憶なし性質を導け。続いてガンマ分布の応用として、独立な指数待ち時間の和を考え、何が観測量で、α と β が何を表すかを説明せよ。

考えるための手がかり

ポアソン分布では $k(k-1)$ を掛けると添字をずらしやすい。幾何分布では $\sum_{k \geq 0} q^k = (1-q)^{-1}$ とその微分、または $\mathbb{E}[X] = \sum_{m \geq 0} P(X > m)$ を使える。記憶なし性質では、条件付き確率の分母が正であることも確認しよう。

解答メモ：パラメータの範囲、値域、密度が 0 となる範囲を省略しない。

発展的内容

回数と待ち時間は、同じ過程の二つの見方

一定時間内に何回起こるかを数えるとポアソン分布、次に起こるまで待つと指数分布。この関係は分布の公式の偶然の一致ではなく、同じランダムな到着過程を異なる方向から観測した結果として理解できる。

短い時間での仮定を置く

$N(t)$ を時刻 t までの到着回数とし、$N(0)=0$ とする。異なる時間区間の増分が独立で、増分の分布は区間の長さだけで決まると仮定する。さらに $h \downarrow 0$ で

$$P(N(h)=1)=\lambda h+o(h), \qquad P(N(h)\geq 2)=o(h)$$

と置く。$\lambda>0$ は単位時間当たりの到着の rate である。これらの仮定の下で、微小時間に複数回到着する寄与は一次の項より小さい。

回数の確率が満たす方程式

$p_k(t)=P(N(t)=k)$ とすると、独立増分を使った畳み込みと上の展開から

$$p_0'(t)=-\lambda p_0(t), \qquad p_k'(t)=-\lambda p_k(t)+\lambda p_{k-1}(t) \quad (k\geq 1).$$

初期条件 $p_0(0)=1$、$p_k(0)=0$（$k\geq 1$）を満たす解は

$$p_k(t)=e^{-\lambda t}\frac{(\lambda t)^k}{k!}.$$

したがって、時刻 t の総回数は $\mathrm{Poi}(\lambda t)$ に従う。

最初の到着まで待つ

$T_1=\inf\{t\geq 0 : N(t)\geq 1\}$ とする。「t より長く待つ」は「時刻 t までに一度も到着しない」と同じだから

$$P(T_1>t)=P(N(t)=0)=e^{-\lambda t}.$$

よって $T_1\sim \mathrm{Exp}(\lambda)$ であり、記憶なし性質も直ちに従う。すでに t 待ったという情報を得ても、さらに待つ時間の分布は同じである。

m 回目の到着まで待つ

T_m を m 回目の到着時刻とすると

$$P(T_m>t)=P(N(t)\leq m-1)=e^{-\lambda t}\sum_{k=0}^{m-1}\frac{(\lambda t)^k}{k!}.$$

この式を微分すると T_m の密度は $\lambda^m t^{m-1}e^{-\lambda t}/(m-1)!$（$t>0$）となる。これは $\mathrm{Gamma}(m,\lambda)$ である。どの現象にも当てはまるわけではなく、独立な増分と一定 rate という仮定がどこまで適切かを確かめることが、分布名を選ぶ前の大切な作業となる。