第6回　二項分布の正規近似

二項分布の中心は $n/2$、幅は $\sqrt{n}/2$ である。中心と幅をそろえると、離散的な確率質量の和が正規密度の積分へ近づく。

公平なコイントスと標準化

$X_1, X_2, \dots$ は独立で $P(X_j = 0) = P(X_j = 1) = 1/2$ とする。表の個数 $S_n = \sum_{j=1}^{n} X_j$ について

$$P(S_n = k) = \binom{n}{k} 2^{-n}, \qquad \mathbb{E}[S_n] = \frac{n}{2}, \qquad \mathrm{Var}(S_n) = \frac{n}{4}.$$

標準化した変数と格子幅は

$$Z_n := \frac{S_n - n/2}{\sqrt{n}/2}, \qquad x_{n,k} := \frac{2k - n}{\sqrt{n}}, \qquad \Delta x = \frac{2}{\sqrt{n}}.$$

Z_n の平均は 0、分散は 1 となる。値の刻みは n とともに小さくなるが、各 n で Z_n は離散型である。

正規密度と Gauss 積分

標準正規密度とその分布関数を

$$\phi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \qquad \Phi(t) := \int_{-\infty}^{t} \phi(x)\, dx$$

とおく。正規化のために $I = \int_{\mathbb{R}} e^{-x^2/2}\, dx$ を計算する。非負積分に Tonelli の定理を使い、極座標に変換すれば

$$I^2 = \int_{\mathbb{R}^2} e^{-(x^2+y^2)/2}\, dx\, dy = 2\pi \int_0^{\infty} r e^{-r^2/2}\, dr = 2\pi.$$

$I > 0$ なので $I = \sqrt{2\pi}$、したがって $\int_{\mathbb{R}} \phi = 1$ となる。

Stirling 公式から中心の高さを求める

階乗の漸近公式

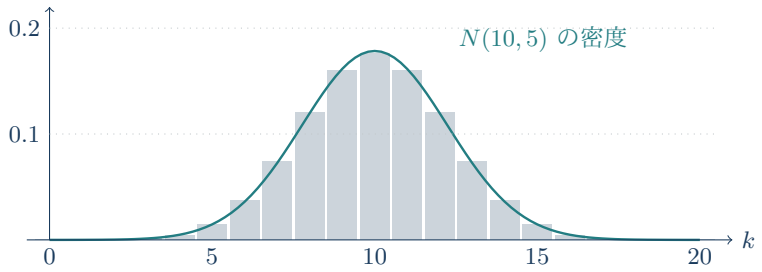
$$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n$$

を使う。偶数 n について中心の確率は

$$P(S_n = n/2) = \frac{n!}{((n/2)!)^2} 2^{-n} \sim \sqrt{\frac{2}{\pi n}} = \phi(0) \frac{2}{\sqrt{n}}.$$

中心の一点の確率は $n^{-1/2}$ 程度となる。 $n = 100$ なら厳密値は約 0.079589、上の近似値は約 0.079788 である。密度の高さそのものに比べるのではなく、格子幅を掛けて比べる点が重要である。

確率質量と正規密度の比較（$n = 20$）



棒の高さは $P(S_{20} = k)$。曲線は平均10・分散5の正規密度で、一点の確率は幅1の区間の面積で近似する。

中心付近の局所近似

固定した $R>0$ に対し、$|x_{n,k}|\le R$ の範囲では

$$P(S_n=k)=\phi(x_{n,k})\frac{2}{\sqrt{n}}\,(1+o(1))$$

が k について一様に成り立つ。 Stirling 公式を二項係数に代入し、$u=(2k-n)/n=x_{n,k}/\sqrt{n}$ とおくと、指数部分には

$$\frac{(1+u)\log(1+u)+(1-u)\log(1-u)}{2}=\frac{u^2}{2}+O(u^4)$$

が現れる。$x_{n,k}$ が有界なら $nu^2=x_{n,k}^2$、$nu^4\to 0$ なので $e^{-x_{n,k}^2/2}$ が残る。係数は $\sqrt{2/(\pi n)}$ に近づく。

確率質量を足すと積分になる

固定した有限区間 $[a,b]$ では、上の一様近似と Riemann 和により

$$P(a\le Z_n\le b)=\sum_{a\le x_{n,k}\le b}P(S_n=k)\longrightarrow\int_a^b\phi(x)\,dx.$$

無限区間に進むには尾を抑える。$\mathbb{E}[Z_n^2]=1$ なので

$$P(|Z_n|>R)\le\frac{1}{R^2}.$$

まず有限区間で $n\to\infty$、次に $R\to\infty$ として

$$P(Z_n\le t)\longrightarrow\Phi(t)\qquad(t\in\mathbb{R})$$

を得る。これが公平なコイントスに対する de Moivre–Laplace の定理である。

実際の計算：連続性補正

整数 $a\le b$ に対し、S_n の一点 k を区間 $[k-1/2,k+1/2]$ に対応させると

$$P(a\le S_n\le b)\approx\Phi\left(\frac{b+1/2-n/2}{\sqrt{n}/2}\right)-\Phi\left(\frac{a-1/2-n/2}{\sqrt{n}/2}\right).$$

たとえば $n=100$、$a=45$、$b=55$ では $\Phi(1.1)-\Phi(-1.1)$ となる。これは有限 n での精度を改善する方法であり、極限定理の主張そのものとは区別する。

一般の成功確率の場合

固定した $0<p<1$ に対しても、独立な $\mathrm{Bern}(p)$ の和は

$$\frac{S_n-np}{\sqrt{np(1-p)}}\ \Rightarrow\ N(0,1).$$

$\Rightarrow$ は分布収束を表す。一般の独立同分布列への拡張は第10回に扱う。小さい n や極端な尾では、正規近似の誤差に注意する。

演習問題

1. 独立な $X_j \sim \mathrm{Bern}(p)$ に対し、$\mathbb{E}[S_n]$ と $\mathrm{Var}(S_n)$ を求めよ。標準化で平均 0、分散 1 になることを確かめよ。
2. $S_{100} \sim \mathrm{Bin}(100, 1/2)$ について、$P(45 \le S_{100} \le 55)$ を連続性補正あり・なしで正規近似せよ。厳密な二項和と比べよ。
3. Z_n の局所近似を用いて、有限な $a < b$ に対する区間確率の収束を示せ。各項の近似誤差を足し合わせるため、一様性をどこで使うか説明せよ。
4. $P(|Z_n| > R) \le R^{-2}$ を証明し、有限区間での収束から分布関数の収束へ進む際の誤差を評価せよ。

レポート問題

1. $n = 100$ の公平なコイントスを 10 000 回反復するシミュレーションを行え。S_n の確率質量のヒストグラムに、$N(50, 25)$ の密度を重ねよ。標準化して描く場合は、密度と確率質量のどちらを表示しているか明記せよ。
2. $n = 20, 50, 200$ の結果を比較し、中心部と尾部の近似誤差、および連続性補正の効果を考察せよ。試行回数を増やしても残る理論上の近似誤差と、反復回数による標本の揺らぎを区別して述べよ。

考えるための手がかり

幅 h のビンの度数を全反復回数だけで割ると確率質量、さらに h で割ると密度の推定になる。Z_n の格子幅は $2/\sqrt{n}$ なので、正規密度と確率質量を直接重ねると縦軸が合わない。数値実験を行う場合は、使用した乱数生成方法と反復回数も記録しよう。

解答メモ：中心化、標準化、格子幅、端点の補正を順に確認する。

発展的内容

コインの足し算から、ランダムな軌跡へ

コインの表の個数を数える代わりに、表なら右へ一歩、裏なら左へ一歩進む。同じコイントスの列が、確率分布だけでなく時間とともに動く道のモデルを与える。

位置の大きさは $\sqrt{n}$ 程度

$Y_j = 2X_j - 1 \in \{-1, 1\}$、$R_m = \sum_{j=1}^{m} Y_j$ とおく。独立性と対称性から

$$\mathbb{E}[R_m] = 0, \qquad \mathrm{Var}(R_m) = m, \qquad \frac{R_n}{\sqrt{n}} = Z_n \Rightarrow N(0,1).$$

一歩ずつは同じ長さでも、右と左が打ち消し合うため、典型的な位置の幅は $\sqrt{n}$ となる。一方向へ進み続ける場合の距離 n とは異なる尺度である。

時間と空間を同時に縮める

時間間隔を $1/n$、歩幅を $1/\sqrt{n}$ とし、格子時刻で

$$W^{(n)}(k/n) = \frac{R_k}{\sqrt{n}}$$

と定め、格子点の間を線形に補間する。各時刻 t での分散はほぼ t、増分の分散はほぼ経過時間となる。たとえば補間前の値について $s \le t$ なら

$$\mathrm{Cov}\left(\frac{R_{\lfloor ns \rfloor}}{\sqrt{n}}, \frac{R_{\lfloor nt \rfloor}}{\sqrt{n}}\right) = \frac{\lfloor ns \rfloor}{n} \longrightarrow s = \min\{s, t\}.$$

過去までに共有した歩数が、二つの時刻の位置の相関を決めている。

極限としての Brown 運動

Brown 運動 $(B_t)_{t \ge 0}$ は $B_0 = 0$、連続な軌跡、独立な増分をもち、$B_t - B_s \sim N(0, t-s)$ $(0 \le s < t)$ を満たす過程である。一時刻の中心極限定理を、連続な軌跡全体の収束へ強めると、補間した $W^{(n)}$ は $C([0,1])$ 上で Brown 運動へ弱収束する。この主張は Donsker の不変原理の、公平な符号列に対する場合である。

一時刻の定理と軌跡の定理の違い

各固定時刻の分布が近づくだけでは、軌跡全体が近づくとは限らない。複数時刻の同時分布に加え、短い時間で大きく振動しすぎないことも制御する必要がある。本講義の中心極限定理はその入口である。分布の収束を学ぶときには、何がランダムな対象なのかが、数から関数へ広がる点も意識してみよう。